

Линейная регрессия и градиентный спуск

Елена Кантонистова
ekantonistova@hse.ru

НИУ ВШЭ



План лекции

- 1 Линейная регрессия: напоминание и пример
- 2 Функция потерь: MSE, MAE, квантильная
- 3 Почему MSE? Метод максимума правдоподобия
- 4 Нечисловые и «нелинейные» признаки
- 5 Аналитическое решение задачи МНК
- 6 Градиентный спуск и его модификации



Линейная регрессия

Напоминание: модель, обозначения и небольшой пример целиком

Линейная регрессия

Пример (напоминание)

Хотим предсказать стоимость дома y по его площади x_1 и количеству комнат x_2 .

$$a(x) = w_0 + w_1x_1 + w_2x_2$$

где w_0 , w_1 , w_2 — параметры модели (веса).



Линейная регрессия

Пример (напоминание)

Хотим предсказать стоимость дома y по его площади x_1 и количеству комнат x_2 .

$$a(x) = w_0 + w_1x_1 + w_2x_2$$

где w_0 , w_1 , w_2 — параметры модели (веса).



Что нам даёт такая модель

- прогноз для нового объекта — подставили признаки, получили число;
- интерпретацию — вес показывает, на сколько меняется прогноз при росте признака на единицу.

Линейная регрессия: общий вид

$$a(x) = w_0 + w_1x_1 + w_2x_2 + \cdots + w_nx_n$$

где $x_1, \dots, x_n$ — признаки объекта x , а n — их количество.

Сокращённая запись:

$$a(x) = w_0 + \sum_{j=1}^n w_jx_j$$

Сумма по всем признакам, отдельно стоит свободный член w_0 (его ещё называют сдвигом, *intercept*).

Линейная регрессия: векторная запись

Добавим фиктивный признак $x_0 = 1$ — тогда свободный член перестанет выбиваться из общей суммы:

$$a(x) = w_0 \cdot 1 + \sum_{j=1}^n w_j x_j = \sum_{j=0}^n w_j x_j = \langle w, x \rangle$$

$$a(x) = \langle w, x \rangle$$

Вся модель — одно скалярное произведение вектора весов на вектор признаков. Дальше всюду пользуемся этой записью.

Что значит «обучить модель»

Обучение линейной регрессии — минимизация среднеквадратичной ошибки по весам:

$$Q(a, X) = \frac{1}{l} \sum_{i=1}^l (a(x_i) - y_i)^2 = \frac{1}{l} \sum_{i=1}^l (\langle w, x_i \rangle - y_i)^2 \rightarrow \min_w$$

здесь l — количество объектов обучающей выборки

Что фиксировано

Данные: объекты $x_1, \dots, x_l$ и их ответы $y_1, \dots, y_l$. Мы их не меняем.

Что подбираем

Веса $w_0, w_1, \dots, w_n$ — ровно $n + 1$ число. Это и есть «обучение».

Разберём пример целиком

Шаг 1. Данные: шесть домов

№	Площадь x_1 , м ²	Комнат x_2	Цена y , млн ₽
1	35	1	6.0
2	45	2	8.2
3	55	2	9.5
4	62	3	11.0
5	78	3	13.4
6	95	4	16.1



Обозначения

- $l = 6$ — объектов
- $n = 2$ — признака
- X — матрица 6×3 (с колонкой единиц)
- y — вектор из 6 чисел

Данные учебные: настоящая выборка по недвижимости — это тысячи объектов и десятки признаков.

Разберём пример целиком

Шаг 2. Обучили модель — получили веса

$$a(x) = 0.68 + 0.138 x_1 + 0.600 x_2$$

Как это читать

$$w_1 = 0.138$$

каждый дополнительный квадратный метр добавляет к прогнозу примерно 138 тыс. ₽ — при том же числе комнат

$$w_2 = 0.600$$


лишняя комната при той же площади добавляет ≈ 600 тыс. ₽

$$w_0 = 0.68$$

формальный сдвиг (базовый уровень цены)

Разберём пример целиком

Шаг 3. Смотрим, как модель ложится на данные



Что видно

Прогноз идёт почти вплотную к факту, но нигде не совпадает с ним точно. Это нормально: модель — не таблица, она сглаживает данные.

Разберём пример целиком

Шаг 4. Прогноз для нового дома и остатки на обучающих данных

Новый дом: 70 м², 3 комнаты

$$a = 0.68 + 0.138 \cdot 70 + 0.600 \cdot 3 \approx 12.15$$

млн ₽

Дом	Факт y	Прогноз a(x)	Остаток y – a(x)
1	6.0	6.12	–0.12
2	8.2	8.10	+0.10
3	9.5	9.48	+0.02
4	11.0	11.05	–0.05
5	13.4	13.26	+0.14
6	16.1	16.21	–0.11

Разберём пример целиком

Шаг 4. Прогноз для нового дома и остатки на обучающих данных

Новый дом: 70 м², 3 комнаты

$$a = 0.68 + 0.138 \cdot 70 + 0.600 \cdot 3 \approx 12.15$$

млн ₽

Дом	Факт y	Прогноз a(x)	Остаток y – a(x)
1	6.0	6.12	–0.12
2	8.2	8.10	+0.10
3	9.5	9.48	+0.02
4	11.0	11.05	–0.05
5	13.4	13.26	+0.14
6	16.1	16.21	–0.11

Важный вопрос

Откуда берутся веса?

Разберём пример целиком

Шаг 4. Прогноз для нового дома и остатки на обучающих данных

Новый дом: 70 м², 3 комнаты

$$a = 0.68 + 0.138 \cdot 70 + 0.600 \cdot 3 \approx 12.15$$

млн ₽

Дом	Факт y	Прогноз a(x)	Остаток y – a(x)
1	6.0	6.12	–0.12
2	8.2	8.10	+0.10
3	9.5	9.48	+0.02
4	11.0	11.05	–0.05
5	13.4	13.26	+0.14
6	16.1	16.21	–0.11

Важный вопрос

Веса взялись не из воздуха: **их подобрали так, чтобы остатки были как можно меньше.**

Но что значит «меньше» для целого столбца чисел?



Функция потерь

Как одним числом измерить, насколько модель плоха

Первая идея

Просто сложим остатки:

$$Q = \sum_{i=1}^l (a(x_i) - y_i)$$

Первая идея

Просто сложим остатки:

$$Q = \sum_{i=1}^l (a(x_i) - y_i)$$

Почему так нельзя

Пусть на одном доме модель ошиблась на +5 млн, а на другом на −5 млн. Сумма остатков равна нулю — формально «идеальная» модель, хотя обе оценки катастрофически плохие.

Ошибки разных знаков гасят друг друга. Значит, знак нужно убрать.

Как убрать знак?

Два естественных способа

Модуль

$$|a(x_i) - y_i|$$

Честно измеряет расстояние.

Квадрат

$$(a(x_i) - y_i)^2$$

Тоже убирает знак, гладкий всюду, легко дифференцируется. Именно его берут по умолчанию.

Оба варианта рабочие. Дальше разберём каждый и увидим, что выбор зависит от того, как устроены ваши данные.

MSE — среднеквадратичная ошибка

Mean Squared Error

$$\text{MSE}(a, X) = \frac{1}{l} \sum_{i=1}^l (a(x_i) - y_i)^2$$

Почему именно квадрат — три причины

- 1 **Убирает знак.** ошибки +5 и −5 больше не компенсируют друг друга
- 2 **Сильнее штрафует большие промахи.** ошибка в 2 раза больше даёт вклад в 4 раза больше — модель старается избегать грубых промахов
- 3 **Гладкая функция.** производная есть всюду, что критично для градиентного спуска


MAE — средняя абсолютная ошибка

Mean Absolute Error

$$\text{MAE}(a, X) = \frac{1}{l} \sum_{i=1}^l |a(x_i) - y_i|$$

Чем отличается от MSE: растёт линейно, а не квадратично.
Большой промах для MAE — это просто большой промах, а не катастрофа.

MAE тоже измеряется в единицах ответа — отдельный корень не нужен.



Где MSE подводит

Один выброс перетягивает всю модель

Пять почти одинаковых домов, но у пятого в базе опечатка — лишний ноль в цене:

Дом	1	2	3	4	5 (опечатка)
Цена у, млн ₽	2.0	2.1	1.9	2.0	10.0

Если минимизировать MSE

константный прогноз = среднее = 3.6

Ни один нормальный дом столько не стоит: выброс утащил прогноз вверх более чем на полтора миллиона.

Если минимизировать MAE

константный прогноз = медиана = 2.0

Выброс учтён, но не задаёт ответ. MAE устойчив к выбросам — это его главное преимущество.

Оптимумы MSE и MAE

Предположим, что на объектах с одинаковым признаковым описанием могут быть разные ответы. Тогда на всех таких объектах модель обязана выдать одно и то же число — какое именно, зависит от функции потерь.

Теорема

Пусть даны l объектов с одинаковым признаковым описанием и значениями целевой переменной $y_1, \dots, y_l$. Тогда:

1. Оптимум MSE достигается на среднем значении ответов:

$$\alpha_{\text{MSE}} = \frac{1}{l} \sum_{i=1}^l y_i$$

2. Оптимум MAE достигается на медиане ответов:

$$\alpha_{\text{MAE}} = \text{median} \{y_1, \dots, y_l\}$$

Оптимумы MSE и MAE

Теорема

Пусть даны l объектов с одинаковым признаковым описанием и значениями целевой переменной $y_1, \dots, y_l$. Тогда оптимальное предсказание (одно и то же число) минимизирует MSE на среднем значении и MAE на медиане этих ответов.

1. Минимум MSE достигается на среднем значении

Рассмотрим функцию потерь как функцию одного числа a :

$$L_{\text{MSE}}(a) = \frac{1}{l} \sum_{i=1}^l (y_i - a)^2.$$

Найдём минимум. Производная равна

$$\frac{d}{da} L_{\text{MSE}}(a) = \frac{2}{l} \sum_{i=1}^l (a - y_i) = 2 \left(a - \frac{1}{l} \sum_{i=1}^l y_i \right).$$

Приравниваем производную к нулю:

$$a = \frac{1}{l} \sum_{i=1}^l y_i.$$

Так как функция квадратичная и выпуклая, это — глобальный минимум.

2. Минимум MAE достигается на медиане

Рассмотрим функцию потерь

$$L_{\text{MAE}}(a) = \frac{1}{l} \sum_{i=1}^l |y_i - a|.$$

Упорядочим ответы по возрастанию:

$$y_{(1)} \leq y_{(2)} \leq \dots \leq y_{(l)}.$$

Функция $L_{\text{MAE}}(a)$ — сумма расстояний до точек y_i .

Если a меньше медианы, то сдвиг a вправо уменьшает расстояния до большинства точек и, значит, уменьшает сумму. Если a больше медианы, то сдвиг влево уменьшает сумму. Поэтому минимум достигается в точке, где слева и справа от a одинаковое количество точек — то есть в медиане:

$$a = \text{median}\{y_1, \dots, y_l\}.$$



Именно поэтому в примере с оценкой MSE дали 3.6 (среднее), а MAE — 2.0 (медиану). Среднее чувствительно к одному большому значению, медиана — нет.

Квантильная регрессия

Функция потерь, которая штрафует промахи вверх и вниз по-разному

$$Q(a, X) = \sum_{i=1}^l \rho_{\tau}(y_i - a(x_i))$$


где

$$\rho_{\tau}(z) = (\tau - 1)[z < 0] z + \tau[z \geq 0] z$$

Параметр $\tau \in [0; 1]$.

Чем больше τ , тем сильнее штрафует за занижение прогноза.

При $\tau = 0.5$ получается обычный MAE (с точностью до множителя).



Вероятностный смысл квантильных потерь

Теорема

Пусть в каждой точке $x \in X$ (пространство объектов) задано распределение $p(y/x)$ на ответах для данного объекта. Тогда оптимизация функции потерь $\rho_\tau(z)$ даёт алгоритм $a(x)$, приближающий τ -квантиль распределения ответов в каждой точке $x \in X$.



Зачем это нужно на практике

Склад и закупки

занижение спроса стоит дороже завышения: пустая полка — потерянные продажи. Берём $\tau \approx 0.9$ и прогнозируем «с запасом»

Сроки доставки

обещать клиенту медианный срок рискованно. Обещают верхнюю квантиль — её выдерживают в 90 % случаев

Прогноз интервала

обучив две модели с $\tau = 0.1$ и $\tau = 0.9$, получаем не точку, а коридор, в который ответ попадает в 80 % случаев

Как выбирать функцию потерь

Функция потерь	Что оптимизирует	Когда брать
MSE	среднее ответов	данные чистые, большие промахи особенно нежелательны
MAE	медиану ответов	в данных есть выбросы или тяжёлые хвосты
Квантильная ρ_τ	τ -квантиль ответов	ошибки вверх и вниз стоят по-разному

Главная мысль

Функция потерь — это не техническая деталь, а формулировка того, что для нас значит «ошибиться». Она должна приходить из задачи, а не из привычки.



Почему всё-таки чаще всего MSE?

Метод максимума правдоподобия: откуда квадрат берётся не из удобства, а из предположений о данных

Метод максимума правдоподобия на пальцах

Подбросили монетку 10 раз, выпало 7 орлов. Какова вероятность орла p у этой монетки?

Идея метода: перебрать все возможные p и выбрать то, при котором наблюдаемый результат наиболее вероятен.

$$p = 0.1$$

вероятность
увидеть 7 орлов

0.000009

почти невозможно

$$p = 0.5$$

вероятность
увидеть 7 орлов

0.117

правдоподобно

$$p = 0.7$$

вероятность
увидеть 7 орлов

0.267

самый вероятный вариант

$$p = 0.9$$

вероятность
увидеть 7 орлов

0.057

снова маловероятно



$$P(X = 7) = C_{10}^7 \cdot 0.7^7 \cdot 0.3^3$$

Победил $p = 0.7$ — ровно доля орлов в эксперименте. Это и есть оценка максимального правдоподобия.

Рецепт метода максимума правдоподобия

1

Придумать вероятностную модель данных

записать, с какой вероятностью появляется наблюдаемый ответ, если параметр равен заданному значению

2

Записать правдоподобие выборки

перемножить вероятности всех наблюдений — это законно, если объекты независимы

3

Максимизировать по параметру

найти то значение параметра, при котором произведение максимально

4

Перейти к логарифму

логарифм монотонен, максимум не сдвигается, а произведение превращается в сумму — считать становится проще

Вероятностная постановка

Даже если целевая переменная линейно зависит от признаков, идеальной модели не существует: реальные ответы будут отличаться от предсказаний, поэтому мы пишем

$$y \approx \langle w, x \rangle$$

Неидеальность прогноза можно объяснить неполнотой данных или шумом в них. Тогда формула переписывается со знаком равенства:

$$y = \langle w, x \rangle + \varepsilon$$

где ε — шум в данных.

Предположение о шуме

Шум в данных обычно имеет некоторое распределение. В большинстве реальных задач считается, что

$$\varepsilon \sim N(0, \sigma^2)$$

Отсюда получаем, что

$$y \sim N(\langle w, x \rangle, \sigma^2)$$

При фиксированных признаках x ответ y не предопределён — он «размазан» вокруг прямой $\langle w, x \rangle$ колоколом нормального распределения. Центр колокола задаёт модель, ширину — уровень шума σ .

Что значит «подобрать оптимальные веса»

$$p(y \mid x, w) \sim N(\langle w, x \rangle, \sigma^2)$$

Это означает, что вероятность наблюдать y при данных значениях x задаётся нормальной плотностью с центром в прогнозе модели.

Мы хотим подобрать такой вектор w , при котором вероятность наблюдать имеющиеся ответы y максимальна.

Запишем это желание сразу для всех объектов выборки — в предположении, что объекты независимы:

$$p(\mathbf{y} \mid X, w) = p(y_1 \mid x_1, w) \cdot p(y_2 \mid x_2, w) \cdot \dots \cdot p(y_l \mid x_l, w) \rightarrow \max_w$$

Функция правдоподобия

Величина $p(y | X, w)$ называется функцией правдоподобия (или правдоподобием) выборки.

Важно понимать, что это функция не от данных, а от весов

- Данные уже собраны и зафиксированы: y и X мы не меняем. Меняется только w — и для каждого набора весов мы можем спросить: «а насколько вероятно было увидеть именно такие ответы, если бы истинная модель имела эти веса?»
- Тот набор весов, который даёт наибольшую вероятность, мы и объявляем ответом. Ровно как с монеткой, где мы перебирали p .

ММП для линейной регрессии

Модель данных с некоррелированным гауссовским шумом:

$$y_i = \langle w, x_i \rangle + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2), \quad i = 1, \dots, l$$

Тогда $y_i \sim N(\langle w, x_i \rangle, \sigma^2), \quad i = 1, \dots, l$

Метод максимума правдоподобия (ММП):

$$L(y_1, \dots, y_l \mid w) = \prod_{i=1}^l \frac{1}{\sigma \sqrt{2\pi}} \exp\left(-\frac{1}{2\sigma^2} (y_i - \langle w, x_i \rangle)^2\right) \rightarrow \max_w$$

Логарифмируем — и получаем МНК

Произведение экспонент неудобно. Возьмём логарифм со знаком минус: максимум превратится в минимум, произведение — в сумму, а экспонента исчезнет.

$$-\ln L(y_1, \dots, y_l \mid w) = \text{const} + \frac{1}{2\sigma^2} \sum_{i=1}^l (y_i - \langle w, x_i \rangle)^2 \rightarrow \min_w$$

Константа и множитель $1/2\sigma^2$ не зависят от w — на точку минимума они не влияют. Остаётся ровно сумма квадратов остатков.

В данном случае ММП совпадает с МНК

МНК — метод наименьших квадратов, англ. OLS (ordinary least squares).

Что мы на самом деле выяснили

MSE — не «просто удобная формула». Выбирая MSE, мы предполагаем, что шум в данных нормальный.

Предположение о шуме	Что даёт ММП	Знакомая функция потерь
$\varepsilon \sim N(0, \sigma^2)$ — нормальный	сумма квадратов остатков	MSE
$\varepsilon \sim \text{Лаплас}$ — тяжелее хвосты	сумма модулей остатков	MAE
несимметричный штраф	квантильная функция ρ_τ	квантильная регрессия

Вывод: если в данных есть существенные выбросы, предположение о нормально распределенном шуме может быть неадекватным. Как следствие — получим большие значения MSE и плохо соответствующую реальности модель.



Особенности применения

Что делать, когда признаки не числовые или влияют не монотонно

О применимости линейной модели

Пример

Предположим, что мы хотим предсказать стоимость дома y по его площади x_1 , количеству комнат x_2 , району x_3 и удалённости от МКАД x_4 .

$$a(x) = w_0 + w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4$$



С какими проблемами столкнемся?

О применимости линейной модели

Пример

Предположим, что мы хотим предсказать стоимость дома y по его площади x_1 , количеству комнат x_2 , району x_3 и удалённости от МКАД x_4 .

$$a(x) = w_0 + w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4$$



Проблема №1

Район x_3 — это не число, а название: Мамыри, Дудкино, Барвиха...

Проблема №2

Удалённость от МКАД x_4 влияет на стоимость не монотонно.

Проблема №1: район - категориальный признак

Первое решение — занумеровать районы. Мамыри = 1, Дудкино = 2, Барвиха = 3.

$$a(x) = \dots + w_3 \cdot x_3$$

Хороший ли подход?

Проблема №1: район - категориальный признак

Первое решение — занумеровать районы. Мамыри = 1, Дудкино = 2, Барвиха = 3. Так делать нельзя.

$$a(x) = \dots + w_3 \cdot x_3$$

Что при должно выполняться (что не так):

- районы упорядочены: Барвиха «больше» Дудкина, а Дудкино «больше» Мамырей;
- расстояния между ними одинаковы: переход $1 \rightarrow 2$ меняет цену ровно так же, как $2 \rightarrow 3$;
- эффект линеен: район № 10 влияет на цену в десять раз сильнее района № 1.

Ни одно из этих утверждений про районы не верно. Модель выучит несуществующий порядок и будет ошибаться.

One-hot encoding (ONE)

Решение проблемы №1

Создаём новые числовые столбцы, каждый из которых является индикатором района.

Район	Мамыри	Дудкино	Барвиха
Дудкино	0	1	0
Барвиха	0	0	1
Мамыри	1	0	0
...	...	...	...
Барвиха	0	0	1

Один столбец на
каждое значение
категории. В каждой
строке ровно одна
единица.

$$a(x) = w_0 + w_1x_1 + w_2x_2 + w_{31}x_{\text{Мамыри}} + w_{32}x_{\text{Дудкино}} + w_{33}x_{\text{Барвиха}} + w_4x_4$$

Теперь у каждого района свой вес — никакого навязанного порядка между ними нет.

Две технические оговорки про ONE

1. Линейная зависимость столбцов (dummy variable trap)

Сумма всех индикаторных столбцов тождественно равна единице — то есть в точности равна фиктивному столбцу x_0 . Матрица X оказывается вырожденной, и аналитическая формула, которую мы выведем дальше, перестаёт работать. Лечится удалением одного столбца (`drop_first`) или регуляризацией.

2. Категории с большим числом значений

Если районов не три, а три тысячи, ONE добавит три тысячи столбцов, в каждом из которых почти везде нули. Модель станет огромной, а по редким районам данных всё равно не хватит. В таких случаях используют группировку редких категорий или счётчики (target encoding).


Проблема №2: немонотонное влияние признака

Удалённость от МКАД влияет на стоимость дома не монотонно: у самой кольцевой — шумно и грязно, очень далеко — неудобно добираться, а оптимум где-то посередине.

Почему это ломает модель

Слагаемое $w_4 \cdot x_4$ умеет только одно: равномерно повышать или равномерно понижать прогноз с ростом x_4 . Изобразить «сначала вверх, потом вниз» оно не способно ни при каком весе.

Как быть?



Бинаризация (разбиение на бины)

Решение проблемы №2

Разобьём диапазон значений на интервалы и сделаем из каждого интервала отдельный индикаторный признак:

$x_{[0;10)}$ = 1, если дом ближе 10 км от МКАД, иначе 0

$x_{[10;30)}$ = 1, если дом в 10–30 км от МКАД, иначе 0

$x_{[30;50)}$ = 1, если дом в 30–50 км от МКАД, иначе 0

$x_{\geq 50}$ = 1, если дом дальше 50 км от МКАД, иначе 0

$$a(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_{41}x_{[0;10)} + w_{42}x_{[10;30)} + w_{43}x_{[30;50)} + w_{44}x_{\geq 50}$$

У каждого интервала — свой вес, поэтому кривая любой формы теперь воспроизводима ступеньками.

Важный вывод

Линейная модель линейна по весам, а не по исходным признакам.

Признаки можно преобразовывать как угодно — модель останется линейной, а значит, сохранит и аналитическое решение, и быстрое обучение:

- **ОНЕ** — категории $\rightarrow$ индикаторы
- **Бинаризация** — числовой признак $\rightarrow$ интервалы
- **Логарифм** — $\log(x)$ вместо x при сильном разбросе
- **Степени** — x^2, x^3 — полиномиальная регрессия
- **Произведения** — $x_1 \cdot x_2$ — учёт взаимодействий признаков

5

Аналитическое решение

Задачу МНК можно решить точно, одной формулой — и понять, почему на практике так делают редко

Задача обучения в матричной форме

Соберём все объекты в матрицу X размера $l \times (n+1)$, а ответы — в вектор y длины l . Тогда все прогнозы сразу — это Xw , а все остатки — $Xw - y$.

$$\frac{1}{l} \|Xw - y\|^2 \rightarrow \min_w$$

Обозначение	Что это	Размер
X	матрица «объекты × признаки», первый столбец — единицы	$l \times (n+1)$
w	вектор весов, который мы ищем	$(n+1) \times 1$
y	вектор истинных ответов	$l \times 1$
$Xw - y$	вектор остатков на всех объектах сразу	$l \times 1$

Сначала — самый простой случай

Один признак, два веса: прямая на плоскости

Прежде чем выводить общую формулу, посмотрим на случай одного признака.

$$a(x) = w_0 + w_1x$$

Функция потерь — сумма квадратов остатков:

$$Q(w_0, w_1) = \sum_{i=1}^l (w_0 + w_1x_i - y_i)^2$$

Это гладкая функция двух переменных, и она выпуклая. Значит, минимум единственный и находится там, где обе частные производные равны нулю.

Приравниваем производные к нулю

$$\frac{\partial Q}{\partial w_0} = 2 \sum_{i=1}^l (w_0 + w_1 x_i - y_i) = 0$$

$$\frac{\partial Q}{\partial w_1} = 2 \sum_{i=1}^l (w_0 + w_1 x_i - y_i) x_i = 0$$

Преобразуем:

$$\begin{aligned} l w_0 + w_1 \sum_{i=1}^l x_i &= \sum_{i=1}^l y_i \\ w_0 \sum_{i=1}^l x_i + w_1 \sum_{i=1}^l x_i^2 &= \sum_{i=1}^l x_i y_i \end{aligned}$$

Два уравнения, два неизвестных — решается единственное.

Готовые формулы для одномерного случая

Из первого уравнения получаем, что прямая проходит через «центр масс» выборки — точку со средними координатами:

$$w_0 = \bar{y} - w_1 \bar{x}$$

Подставив это во второе уравнение, получаем наклон:

$$w_1 = \frac{\sum_{i=1}^l (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^l (x_i - \bar{x})^2}$$

В числителе — выборочная ковариация x и y , в знаменателе — дисперсия x . То есть наклон прямой показывает, насколько согласованно признак и ответ отклоняются от своих средних.

Считаем на наших шести домах

Признак один — площадь

	1	2	3	4	5	6	среднее
x — площадь	35	45	55	62	78	95	61.67
y — цена	6.0	8.2	9.5	11.0	13.4	16.1	10.70

$$w_1 = \frac{399.2}{2411.3} \approx 0.1656$$

$$w_0 = 10.70 - 0.1656 \cdot 61.67 \approx 0.491$$

$$a(x) = 0.491 + 0.1656 x$$

Проверка: для дома 62 м² модель даёт $0.491 + 0.1656 \cdot 62 \approx 10.76$ млн ₽ при факте 11.0. RMSE такой модели ≈ 0.20 млн ₽ — вдвое хуже, чем у модели с двумя признаками.

В общем случае

Раскроем квадрат нормы (множитель $1/l$ на точку минимума не влияет, опустим его):

$$Q(w) = \|Xw - y\|^2 = (Xw - y)^T (Xw - y) = w^T X^T X w - 2w^T X^T y + y^T y$$

Дифференцируем по правилам матричного дифференцирования:

$$\nabla_w Q = 2X^T X w - 2X^T y$$

В общем случае

Раскроем квадрат нормы (множитель $1/l$ на точку минимума не влияет, опустим его):

$$Q(w) = \|Xw - y\|^2 = (Xw - y)^T (Xw - y) = w^T X^T X w - 2w^T X^T y + y^T y$$

Дифференцируем, пользуясь задачами 1 и 2 (матрица $X^T X$ симметрична):

$$\nabla_w Q = 2X^T X w - 2X^T y$$

Приравниваем градиент к нулю и получаем:

$$X^T X w = X^T y$$

Если матрица $X^T X$ обратима, домножаем слева на обратную к ней — и всё:

$$w = (X^T X)^{-1} X^T y$$

Аналитическое решение задачи МНК

Задача обучения линейной регрессии (в матричной форме):

$$\frac{1}{l} \|Xw - y\|^2 \rightarrow \min_w$$

Точное (аналитическое) решение:

$$w = (X^T X)^{-1} X^T y$$

Недостатки аналитической формулы

Дорого считать

обращение матрицы — операция сложности $O(n^3)$ от числа признаков. При n порядка десятков тысяч это неприемлемо, а в промышленных задачах признаков бывает и больше

Матрица может быть вырожденной

$X^T X$ необратима, если признаки линейно зависимы: дубликат столбца, полный набор ONE-столбцов вместе с константой, признак «площадь в m^2 » рядом с «площадью в футах 2 »

...или плохо обусловленной

формально обратима, но почти вырождена. Тогда крошечное изменение данных даёт огромный скачок весов — модель становится неустойчивой и неинтерпретируемой

Работает только для MSE


стоит заменить среднеквадратичный функционал на MAE или квантильный — и аналитического решения, скорее всего, не будет вовсе



Градиентный спуск

Универсальный численный метод: спускаемся к минимуму маленькими шагами

Теорема о градиенте



Градиент

вектор, в направлении которого функция быстрее всего растёт.

Антиградиент

вектор, противоположный градиенту: направление, в котором функция быстрее всего убывает.


Отсюда сразу следует идея метода

Мы ищем минимум функции потерь. Значит, из текущей точки надо шагнуть в сторону антиградиента — это направление самого быстрого убывания функции. Сделать шаг, пересчитать градиент в новой точке, шагнуть снова. И так до сходимости.

Метод градиентного спуска: идея

- Наша задача при обучении модели — найти такие веса w , на которых достигается минимум функции ошибки.
- В простейшем случае, если ошибка среднеквадратичная, то её график — это парабола (в многомерном случае — параболоид).
- Идея метода: на каждом шаге (на каждой итерации) движемся в сторону антиградиента функции потерь. То есть на каждом шаге движемся в направлении уменьшения ошибки.

Вектор градиента функции потерь обозначают $\text{grad } Q$ или ∇Q .



Метод градиентного спуска: общий случай

Пусть $w_0, w_1, \dots, w_n$ — веса, которые мы ищем. Тогда градиент — это вектор из всех частных производных:

$$\nabla Q(w) = \left(\frac{\partial Q}{\partial w_0}, \frac{\partial Q}{\partial w_1}, \dots, \frac{\partial Q}{\partial w_n} \right)$$

Алгоритм

- Инициализируем веса $w_0^{(0)}, w_1^{(0)}, w_2^{(0)}, \dots, w_n^{(0)}$.
- На каждом следующем шаге обновляем каждый вес:

$$\begin{aligned} w_0^{(k)} &= w_0^{(k-1)} - \frac{\partial Q}{\partial w_0} (w_0^{(k-1)}), \\ &\vdots \\ w_n^{(k)} &= w_n^{(k-1)} - \frac{\partial Q}{\partial w_n} (w_n^{(k-1)}). \end{aligned}$$

Векторная форма и длина шага

Эту формулу удобнее записать сразу для всего вектора весов:

$$w^{(k)} = w^{(k-1)} - \nabla Q(w^{(k-1)})$$

В формулу обычно добавляют параметр η — величину градиентного шага (learning rate). Он отвечает за скорость движения в сторону антиградиента:

$$w^{(k)} = w^{(k-1)} - \eta \nabla Q(w^{(k-1)})$$

Градиент задаёт направление, η — насколько далеко мы по этому направлению шагаем. Это главный настраиваемый параметр (гиперпараметр) метода.

Что гарантирует метод

Если функция $Q(w)$ выпуклая и гладкая, её градиент изменяется достаточно плавно, а также она имеет минимум в точке w^* , то при аккуратно подобранном шаге η метод градиентного спуска гарантированно приближается к оптимальному значению.

Градиент MSE для линейной регрессии

Всё, что нужно подставить в формулу обновления

Функция потерь и её градиент по вектору весов:

$$Q(w) = \frac{1}{l} \sum_{i=1}^l (\langle w, x_i \rangle - y_i)^2$$

$$\nabla Q(w) = \frac{2}{l} \sum_{i=1}^l (\langle w, x_i \rangle - y_i) x_i$$

То же самое в матричном виде:

$$\nabla Q(w) = \frac{2}{l} X^T (Xw - y)$$

Алгоритм целиком

1

Инициализировать веса

$w^{(o)}$ — например, нулями или маленькими случайными числами

2

Вычислить градиент

$$\nabla Q(w^{(k-1)}) = \frac{2}{l} X^T (X w^{(k-1)} - y)$$

3

Сделать шаг

$$w^{(k)} = w^{(k-1)} - \eta \nabla Q(w^{(k-1)})$$

4

Проверить критерий останова

если веса или значение функции потерь почти перестали меняться — останавливаемся, иначе возвращаемся к шагу 2

Метод не требует ни обращения матриц, ни даже того, чтобы функция потерь была именно MSE — достаточно уметь считать градиент.

Варианты инициализации весов

Нулями

$$w_j = 0, j = 1, \dots, n$$

самый простой вариант; для линейной регрессии его достаточно

Небольшими случайными значениями

$$w_j := \text{random}(-\varepsilon, \varepsilon)$$

нужен там, где симметрию весов нельзя оставлять — например, в нейросетях

По небольшой случайной подвыборке

обучаем на нескольких сотнях объектов
получаем разумное начальное приближение почти бесплатно

Мультистарт

несколько запусков из разных начальных точек
выбираем лучшее решение; спасает при невыпуклой функции потерь

Для выпуклой задачи точка старта влияет только на скорость, но не на итоговый ответ.

Критерии останова

Когда пора прекращать итерации

По изменению функции потерь

$$|Q(w^{(k)}) - Q(w^{(k-1)})| < \varepsilon$$

Ошибка почти перестала уменьшаться — дальнейшие шаги ничего не дают.

По изменению весов

$$\|w^{(k)} - w^{(k-1)}\| < \varepsilon$$



Сами веса стабилизировались — модель дальше не меняется.

По норме градиента

$$\|\nabla Q(w^{(k)})\| < \varepsilon$$

Если норма градиента меньше эпсилон — мы у цели!

Проблема выбора градиентного шага



Проблема выбора градиентного шага

В общем случае шаг может зависеть от номера итерации — тогда пишут не η , а η_k :

$$\eta_k = c$$


постоянный шаг

$$\eta_k = \frac{1}{k}$$

убывающий шаг

$$\eta_k = \lambda \left(\frac{s_0}{s_0 + k} \right)^p$$

λ, s_0, p — параметры



Один из недостатков градиентного спуска

С точки зрения реализации

На каждом шаге для вычисления $\nabla Q(w)$ мы вычисляем производную по каждому весу от каждого объекта. То есть вычисляем целую матрицу производных — это затратно и по времени, и по памяти.

Насколько это больно

Пусть в выборке 10 миллионов объектов и 1000 признаков. Чтобы сделать один-единственный шаг, нужно пройти по всем десяти миллионам строк. А шагов понадобятся сотни или тысячи.

При этом соседние шаги дают очень похожие градиенты — мы раз за разом честно пересчитываем почти одно и то же.

Стохастический градиентный спуск

Stochastic gradient descent, SGD

На каждом шаге выбираем **один случайный объект** и сдвигаемся в сторону антиградиента по этому объекту:

$$w^{(k)} = w^{(k-1)} - \eta_k \cdot \nabla q_{i_k}(w^{(k-1)})$$

где $\nabla q_{i_k}(w^{(k-1)})$ — градиент функции потерь, вычисленный только по объекту с номером i_k , а не по всей обучающей выборке.

Гарантии?

Если функция $Q(w)$ выпуклая и гладкая и имеет минимум в точке w^* , то SGD при аккуратно подобранном η через некоторое число шагов гарантированно попадёт в малую окрестность w^* . Однако сходится метод медленнее, чем обычный градиентный спуск: каждый отдельный шаг теперь очень шумный, зато обходится в тысячи раз дешевле.

Mini-batch gradient descent

Промежуточное решение между классическим градиентным спуском и стохастическим

- Выбираем batch size (например, 32, 64 и т. д.). Разбиваем все пары «объект — ответ» на группы такого размера.
- На i -й итерации вычисляем $\nabla Q(w)$ только по объектам i -го батча:

$$w^{(k)} = w^{(k-1)} - \eta_k \cdot \nabla Q_i(w^{(k-1)})$$

где $\nabla Q_i(w^{(k-1)})$ — градиент функции потерь, вычисленный по объектам из i -го батча.

Три варианта градиентного спуска

	Полный GD	Mini-batch	SGD
Объектов на шаг	вся выборка	batch size (32–512)	один
Цена одного шага	высокая	умеренная	минимальная
Шум в градиенте	нет	небольшой	большой
Шагов до сходимости	мало	умеренно	много
Когда применяют	маленькие выборки	почти всегда	поточковые данные

Шумные шаги — не только недостаток: случайность иногда помогает выскочить из плохих локальных минимумов!

Обязательный шаг: масштабирование признаков

Площадь измеряется десятками, число комнат — единицами, цена — миллионами. Для аналитической формулы это безразлично, а для градиентного спуска — нет.

Шаг η один на все веса. Если признаки различаются по масштабу в сотни раз, то шаг, подходящий для одного веса, окажется слишком большим для другого — спуск будет «зигзагом» метаться по оврагу вместо того, чтобы идти к минимуму.

Два стандартных способа

Стандартизация

$$\tilde{x} = \frac{x - \mu}{\sigma}$$

Среднее 0, разброс 1. Выбор по умолчанию.

Min-max нормализация

$$\tilde{x} = \frac{x - \min}{\max - \min}$$

Все значения в отрезке $[0; 1]$. Чувствительна к выбросам.

Параметры масштабирования считают по обучающей выборке и применяют к тестовой — иначе будет утечка данных.

Формула или градиентный спуск?

	Аналитическая формула	Градиентный спуск
Что получаем	точное решение сразу	приближённое, по мере итераций
Сложность	$O(n^3)$ от числа признаков	$O(l \cdot n)$ на одну итерацию
Признаков много ($n > 10^4$)	практически неприменима	работает
Объектов очень много	матрицу держим целиком	SGD и mini-batch справляются
Другая функция потерь	решения обычно нет	достаточно уметь считать градиент
Параметры настройки	нет	η , число итераций, размер батча

Небольшая задача с десятком признаков — берем формулу, она проще и точнее. Всё остальное — градиентный спуск.

Что мы обсудили

- 1 **Модель** — линейная регрессия — это скалярное произведение $a(x) = \langle w, x \rangle$; обучение сводится к подбору вектора весов
- 2 **Функция потерь** — выбор между MSE, MAE и квантильной — это выбор того, что для нас значит «ошибиться»
- 3 **ММП** — MSE не удобная условность: она следует из предположения о нормальном шуме в данных
- 4 **Признаки** — модель линейна по весам, поэтому ONE, бинаризация и другие преобразования полностью законны
- 5 **Точное решение** — $w = (X^T X)^{-1} X^T y$ существует, но дорого считается и требует обратимости $X^T X$
- 6 **Градиентный спуск** — универсальная замена: шагаем против градиента, а SGD и mini-batch делают шаг дешёвым